Informatika Fakultatea
UPV/EHU

eman ta zabal zazu
Universidad del País Vasco
Euskal Herriko Unibertsitatea

Grado en Ingeniería Informática

Sistemas de Cómputo Paralelo

Ingeniería de Computadores

Aprendizaje Basado en Proyectos (segunda parte)

3. Programación paralela: MPI

▪ Pregunta motriz

¡Cuidado, que quema!

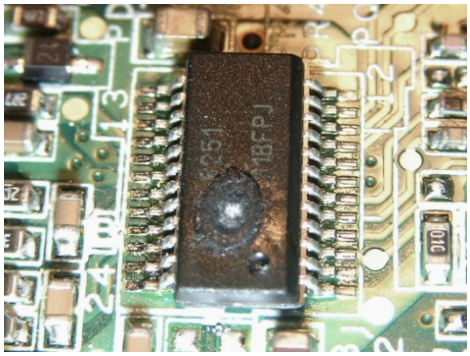

▪ Escenario

La empresa TXIPSA se dedica a la fabricación de placas de circuitos impresos para diversos usos. Estas placas contienen varios chips que se calientan a diferentes temperaturas en su uso normal, por lo que deben ser colocados de forma estratégica en la placa para reducir la temperatura global del sistema y evitar que la placa se queme y deje de funcionar.

Antes de fabricar el circuito final, se simula un algoritmo de difusión del calor usando diferentes localizaciones de los chips en la tarjeta, para elegir aquella configuración que minimiza la temperatura media global de la tarjeta. Para aplicar el algoritmo de difusión del calor, se divide la tarjeta en una rejilla bidimensional de puntos, y se va modificando la temperatura de cada punto teniendo en cuenta la **temperatura de los puntos vecinos**, hasta que, iteración tras iteración, el sistema converge a una determinada temperatura media, que depende de la posición de las fuentes de calor, los chips de la tarjeta.

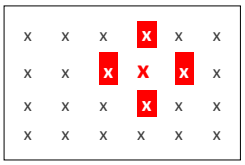

La simulación se hace en un equipo monoprocesador analizando el comportamiento de diferentes configuraciones, hasta obtener la mejor solución. La siguiente figura muestra tres posibles configuraciones de una tarjeta de circuito impreso con tres chips, en las que, tras el proceso de difusión del calor, se alcanzan diferentes temperaturas medias en la tarjeta.

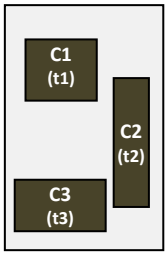

Config. 1 — T_m1

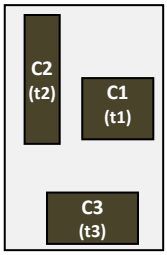

Config. 2 — T_m2

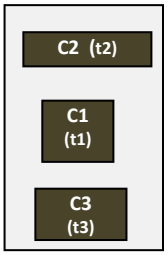

Config. 3 — T_m3

Recientemente TXIPSA ha adquirido un *cluster* de 33 procesadores de **memoria distribuida**, conectados con una red Gigabit Ethernet, y quiere paralelizar el programa de difusión del calor y cálculo de la temperatura media. Así, cada procesador se encargará de simular el comportamiento térmico de un trozo de la tarjeta, calculando entre todos los procesadores la temperatura media final. De esa manera, se pretende realizar más simulaciones en menos tiempo, lo que redundará en una reducción del tiempo de fabricación, y, en su caso, en un aumento de los beneficios.

La empresa te ha encargado que paralelices de manera eficiente la fase de simulación térmica de diferentes configuraciones de los chips en una tarjeta.

▪ Temario a cubrir en el proyecto

El proyecto desarrolla el tema 3 de la asignatura, Programación paralela: MPI. Se abordará el análisis de los problemas que surgen al desarrollar aplicaciones eficientes para ser ejecutadas en sistemas paralelos de memoria distribuida: la comunicación entre procesadores, la definición adecuada de tipos de datos que minimicen el coste de la comunicación, y diversos modelos de planificación de carga (estáticas y dinámicas, basadas éstas en el modelo *manager*/*worker*). Para ello, se trabajará con MPI, la herramienta estándar para la programación de sistemas paralelos de memoria distribuida.

▪ Resultados de aprendizaje

Al término de esta tarea deberás ser capaz de:

- Programar de forma eficiente pequeñas aplicaciones en multiprocesadores de memoria distribuida, utilizando el estándar MPI.
- Analizar el rendimiento que se obtiene en un sistema de cómputo paralelo y de las aplicaciones que en él se ejecuten.

Así mismo, se trabajan otras competencias generales y transversales (ver página web del Grado en Ingeniería Informática, apartado “Plan de estudios”).

▪ Entregables

E1 Acta de constitución del grupo y documento de compromisos de los componentes del grupo (E1.1), junto con las actas de reuniones realizadas para llevar a cabo el proyecto (E1.2).

E2 Póster realizado en el análisis del escenario.

E3 Recopilación del trabajo realizado por cada persona en el puzle: (E3.1) breve informe que incluye el trabajo teórico realizado y la resolución/análisis de los ejercicios planteados; (E3.2) presentación del puzle. Se incorporará el material teórico utilizado para el estudio de las tareas (siempre que se trate de material novedoso no entregado por el profesor).

E4 Actas de las evaluaciones por pares. Por una parte, acta de la evaluación de la presentación del puzle (E4.1) y, por otra, acta de la evaluación de la presentación de la aplicación desarrollada (E4.2).

E5 Examen de control de conocimientos mínimos adquiridos en el desarrollo del proyecto.

E6 Fin de la primera fase de la implementación de la aplicación: breve informe (1 hoja) con los principales resultados obtenidos (E6.1). Informe técnico final de la aplicación desarrollada (E6.2), así como el material realizado para la presentación de la misma (E6.3).

E7 Portafolio o carpeta con el material generado durante el desarrollo del proyecto y que el grupo considere adecuado para su mejor interpretación. Aunque se entregará la versión definitiva al finalizar el proyecto, se entregará una primera versión con el material generado hasta el puzle, que será revisado para que pueda ser mejorado.

Todos los entregables serán cooperativos, grupales, salvo el entregable E5 (examen de conocimientos mínimos), que será un entregable individual.

▪ Sistema de evaluación

El proyecto (segunda parte de la asignatura) se evalúa en 6 puntos, de acuerdo a los siguientes criterios:

- Presentación individual. En el proyecto se contemplan dos presentaciones: puzle y aplicación desarrollada. Cada grupo hará una de las presentaciones. La persona que realice la presentación será elegida en el momento. Dado que esta actividad es colaborativa, la nota obtenida será la nota de todo el grupo. Las presentaciones serán evaluadas por el profesor y estudiantes, y su nota será de **1 punto**.
- Examen individual de conocimientos mínimos. Su valoración será de **2 puntos**. Para superar el proyecto, se deberá obtener una nota mínima en este examen de 30%.
- Informe técnico que describa la aplicación desarrollada y analice el rendimiento obtenido. Esta actividad valdrá **3 puntos**.
- Carpeta o portafolio del proyecto. Esta actividad es de tipo filtro: se calificará como APTA o NO APTA, pero no afecta a la calificación final. En cualquier caso, debe ser superada.

Se considerarán como puntos extra actividades desarrolladas de forma extraordinaria (entre otros aspectos, por ejemplo, un portafolio bien estructurado, actualizado, etc.)

Para aprobar la asignatura hay que obtener al menos 3 puntos en el proyecto. La siguiente tabla resume la evaluación de cada una de las actividades y quién la efectúa.

	Nota	**Profesor/a**		**Estudiantes**	
Individual	2 puntos	Examen (E5)	2 p.		
Grupo	4 puntos	Presentaciones (E3.2/E6.3)	0,5 p.	Presentaciones (E4.1/E4.2)	0,5 p.
		Informe técnico (E6.2)	3 p.		
		Portafolio final (E7)	filtro		
Nota total	**6 puntos**		5,5 p.		0,5 p.

La siguiente tabla muestra un resumen de las actividades a desarrollar, de la carga de trabajo estimada (presencial y no presencial), los entregables a desarrollar, y los hitos de evaluación del proyecto, semana por semana.

Las actividades presenciales se desarrollan en tres sesiones de 1,5 horas los lunes, martes y miércoles de cada semana. Las semanas del 21-23 de marzo (semana santa) y del 16-20 de mayo (fin de trabajos) no tienen actividades presenciales, pero son lectivas.

En la semana de horario agrupado, 18-22 de abril, está prevista una visita al centro de cálculo del DIPC (por confirmar).

PLANIFICACIÓN DEL TRABAJO

Sem.	Clase	Actividades presenciales	t/día	Actividades no presenciales (por semana)	t/sem	Entregables	Evaluación
29 -4/03	1	Entrega del escenario del proyecto y reflexión por grupos	30 m			Acta: constitución de grupo (E1.1)	
		Discusión PBL, póster final	30 m			Póster (din-A4) (E2)	
		Planificación del proyecto	30 m				
	2	Programación en MPI	90 m		3 h		
	3	Programación en MPI	70 m	Estudio programación en MPI			
		Delimitación de tareas concretas: puzle	20 m	Estudio individual del problema asignado en el puzle			
7-11/03	4	Estudio individual del problema asignado en el puzle	90 m	Estudio individual del problema asignado en el puzle	4 h		
	5		90 m				
	6		90 m				
14-18/03	7	Reunión de grupo: puesta en común	90 m	Estudio de todos los conceptos del puzle	4 h		
	8	Reunión de expertos: puesta en común	90 m	Preparación de informe y de la presentación del puzle			
	9	Reunión de grupo: puesta en común	80 m	Ejercicios de representación gráfica			
		Enunciado de los ejercicios de representación gráfica	10 m				
21-23/03				reparación de informe y de la presentación del puzle Ejercicios de representación gráfica	8 h		
4-8/04	10	Ejercicios de representación gráfica	60 m	Preparación presentación puzle	4 h		
		Reunión de grupo: puesta en común	30 m			Puzle: informe (E3.1), presenta-	
	11	Puzle: presentación	90 m			ción (E3.2), acta de eval. (E4.1)	[1 p. (E3.2, E4.1)]
	12	Puzle: debate aclaratorio	70 m	Implementación de la aplicación (Fase 1)		Portafolio para revisión (E7)	
		Enunciado de la aplicación (Fase 1)	20 m				
11-15/04	13	Trabajo: desarrollo de la aplicación	90 m	Desarrollo de la aplicación	4 h		
	14		90 m				
	15		90 m				
18-22/04				Desarrollo de la aplicación	6 h		
25-29/04	16	Trabajo: desarrollo de la aplicación	90 m	Desarrollo de la aplicación	4 h		
	17	Teoría: com. punto a punto, deadlock	60 m			Resultados preliminares: Fase 1	
		Teoría: Jumpshot	30 m			de la aplicación (E6.1)	
	18	Debate de resultados preliminares	15 m	Desarrollo de la aplicación (Fase 2)			
		Enunciado de la aplicación (Fase 2)	15 m				
		Teoría: topologías / anillo. Ejercicio demo: MPI+OpenMP.	60 m				
2-6/05	19	Trabajo: desarrollo de la aplicación (Fase 2)	90 m	Desarrollo de la aplicación	4 h		
	20		90 m				
	21		90 m				
9-13/05	22	Trabajo: desarrollo de la aplicación, documentación	90 m	Desarrollo / documentación	4 h		
	23		90 m				
	24		90 m				
16-20/05				Preparación de la presentación / Estudio	8 h	Informe técnico: Fases 1 y 2 (E6.2)	3 p.
24/05	25	Defensa de la aplicación desarrollada	60 m		3 h	Acta: evaluación de la pres. (E4.2)	[1 p. (E6.3, E4.2)]
		Examen de conocimientos mínimos	120 m			Examen (E5) - Portaf. (E7, filtro)	2 p. (E.5)

Fase previa al puzle: el *cluster* y conceptos básicos de MPI

Antes de comenzar con el puzle, vamos a trabajar en dos sesiones de laboratorio cómo usar el *cluster* y los conceptos básicos de MPI.

El *cluster* de trabajo: máquinas y directorios

Vamos a trabajar con un *cluster* sencillo de 32 nodos (Intel Core 2 6320 - 1,8 GHz - 2 GB RAM - 4 kB cache) más un nodo similar para desarrollo, conectados todos mediante Gigabit Ethernet en una red local. Es un sistema muy simple, pero permite ejecutar todo tipo de aplicaciones paralelas mediante paso de mensajes, analizar su comportamiento, etc.

El nodo de desarrollo hace las veces de servidor de ficheros y de punto de entrada al *cluster*; su dirección externa es **`g002615.gi.ehu.eus`**, y su dirección en el *cluster* es `servidor01` (`nodo00`). El resto de los nodos —`nodo01, nodo02... nodo32`— solo son accesibles desde el nodo de entrada (no tienen conexión al exterior).

En el laboratorio realizaremos la conexión remota desde una sesión local Linux utilizando el comando:

```
> ssh cuenta@g002615.gi.ehu.eus
```

El directorio `templates` contiene en tres carpetas —ejemplos, puzle, aplicación— los ejemplos y programas con los que vamos a trabajar. Haz una copia de esos ficheros a una carpeta en el directorio de trabajo; por ejemplo:

```
> mkdir ejemplos
> cp templates/ejemplos/* ejemplos
```

Generación del entorno de ejecución remoto

Para poder ejecutar aplicaciones utilizando diferentes máquinas necesitamos que el sistema pueda entrar en las mismas usando `ssh` pero sin que se pida *password*. Para ello, hay que haber entrado una primera vez en cada máquina, para que nos reconozca como "usuarios autorizados". Para ello,

1. En el directorio de entrada, se ejecuta:

   ```
   > ssh-keygen -t rsa
   ```
   (respondiendo con `return` las tres veces)

   Se genera el directorio `.ssh` con los ficheros con claves `id.rsa` e `id_rsa.pub`. Pasa a ese nuevo directorio y ejecuta:

   ```
   > cp id_rsa.pub authorized_keys
   > chmod go-rw authorized_keys
   ```

   De nuevo en el directorio principal hay que entrar y salir, una por una, en las máquinas del *cluster*:

   ```
   > ssh nodoxx        (xx = 01 ... 32)
      (yes)
   > exit
   ```

Estas operaciones las hemos definido en el fichero de comandos **`cluster-ssh.sh`**, para poder ejecutarlas automáticamente.

▪ MPICH2

Vamos a utilizar la implementación MPICH2 de MPI (de libre distribución, la podéis instalar en vuestro PC; otra implementación de gran difusión es Open MPI). Previo a ejecutar programas en paralelo, hay que:

2. Crear un fichero de nombre `.mpd.conf` que contenga una línea con el siguiente contenido:

   `secretword=xxxx` (`xxxx` = cualquier palabra)

   y cambiarle los permisos: > `chmod 600 .mpd.conf`

3. Crear un fichero con las lista de las máquinas que vamos a utilizar (por defecto, de nombre `mpd.hosts`). En este caso basta con escribir:

   ```
   nodo00
   nodo01
   …
   nodo32
   ```

Estas dos operaciones también están incluidas en el fichero de comandos **`cluster-ssh.sh`**.

4. Ya solo queda poner en marcha el "entorno" MPICH2 (*daemons* mpd que se van a ejecutar en cada máquina del *cluster*):

   `> mpdboot -v -n num_proc [-f fichero_maquinas]`

   (`-f` si el fichero con la lista de las máquinas no es `mpd.hosts`).

   Otros comandos útiles:

`> mpdtrace`	devuelve las máquinas "activas"
`> mpdlistjobs`	lista los trabajos en ejecución en el anillo de *daemons*
`> mpdringtest 2`	recorre el anillo de máquinas activas (2 veces) y devuelve el tiempo
`> mpd &`	lanza un solo *daemon* en el procesador local
`> mpdhelp`	información de los comandos

   Si ha habido algún problema con la generación de *daemons*, etc., ejecutad `mpdcleanup` y repetid el proceso.

5. A continuación podemos compilar y ejecutar programas:

   `> mpicc [-Ox] -o pr1 pr1.c` [x=1-3 nivel de optimiz.; por defecto, 2]

   `> mpiexec -n xx pr1` xx = número de procesos

   Ejecuta el programa `pr1` en xx procesadores (con el *flag* -1 no se utiliza el nodo 00 para ejecutar los procesos)

   `> mpiexec -n 1 -host nodo00 p1 : -n 1 -host nodo01 p2`

   `> mpiexec -configfile procesos`

   Lanza dos programas, `p1` y `p2`, en los nodos 00 y 01, o bien tal como se especifica en el fichero procesos.

6. Finalmente, para terminar una sesión de trabajo ejecutamos:

   `> mpdallexit`

(para más información sobre estos comandos: `comando --help`)

- **Jumpshot**

Jumpshot es la herramienta de análisis de la ejecución de programas paralelos que se distribuye junto con MPICH. Permite analizar gráficamente ficheros de trazas (tipo "log") obtenidos de la ejecución de programas MPI a los que previamente se les ha añadido una serie de llamadas a MPE para recoger información.

Para generar el fichero log podemos añadir puntos de muestreo en lugares concretos (añadiendo funciones de MPE), o, en casos sencillos, tomar datos de todas las funciones MPI.

```
> mpicc -mpe=mpilog -o prog prog.c
> mpiexec –n xx prog
```

Una vez compilado, lo ejecutamos y obtenemos un fichero de trazas, de tipo clog2. Ahora podemos ejecutar jumpshot para analizar el fichero de trazas obtenido:

```
> jumpshot
```

Jumphot4 trabaja con un formato de tipo slog2, por lo que previamente hay que efectuar una conversión a dicho formato. Esa conversión puede hacerse ya dentro de la aplicación, o ejecutando:

```
> clog2TOslog2 prog.clog2
```

La ventana inicial de jumpshot nos permite escoger el fichero que queremos visualizar. En una nueva ventana aparece un esquema gráfico de la ejecución, en el que las diferentes funciones de MPI se representan con diferentes colores. En el caso de las comunicaciones punto a punto, una flecha une la emisión y recepción de cada mensaje. Con el botón derecho del ratón podemos obtener datos de las funciones ejecutadas y de los mensajes transmitidos.

NOTA: para poder ejecutar esta aplicación gráfica (u otras) de manera remota:

-- Windows >> ejecutar previamente X-Win32 (o una aplicación similar)

-- Linux >> entrar en la máquina ejecutando ssh –X cuenta@máquina

Los siguientes cuatro programas —hola.c, circu.c, envio.c y probe.c— los trabajaremos en las dos primeras sesiones de laboratorio.

```
/*************************************************************
      hola.c
      programa MPI: activacion de procesos
*************************************************************/

#include <mpi.h>
#include <stdio.h>

int main(int argc, char *argv[])
{
  int   lnom;
  char  nombrepr[MPI_MAX_PROCESSOR_NAME];
  int   pid, npr;                       // identificador y numero de proc.
  int   A = 21;

  MPI_Init(&argc, &argv);
  MPI_Comm_size(MPI_COMM_WORLD, &npr);
  MPI_Comm_rank(MPI_COMM_WORLD, &pid);

  MPI_Get_processor_name(nombrepr, &lnom);

  A = A + 1;
  printf(" >> Proceso %2d de %2d activado en %s, A = %d\n", pid,npr,nombrepr,A);

  MPI_Finalize();
  return (0);
 }


/*************************************************************************
      circu.c
      paralelizacion MPI de un bucle
*************************************************************************/

#include <mpi.h>
#include <stdio.h>

#define DECBIN(n,i) ((n&(1<<i))?1:0)

void test (int pid, int z)
{
  int v[16], i;
  for (i=0; i<16; i++) v[i] = DECBIN(z,i);

  if ((v[0] || v[1]) && (!v[1] || !v[3]) && (v[2] || v[3])
     && (!v[3] || !v[4]) && (v[4] || !v[5])
     && (v[5] || !v[6]) && (v[5] || v[6])
     && (v[6] || !v[15]) && (v[7] || !v[8])
     && (!v[7] || !v[13]) && (v[8] || v[9])
     && (v[8] || !v[9]) && (!v[9] || !v[10])
     && (v[9] || v[11]) && (v[10] || v[11])
     && (v[12] || v[13]) && (v[13] || !v[14])
     && (v[14] || v[15]))
  {
    printf("   %d)   %d%d%d%d%d%d%d%d%d%d%d%d%d%d%d%d   (%d)\n",   pid,   v[15],v[14],v[13],
       v[12],v[11],v[10],v[9],v[8],v[7],v[6],v[5],v[4],v[3],v[2],v[1],v[0], z);
    fflush(stdout);
  }
}

int main (int argc, char *argv[])
{
  int   i, pid, npr;
  MPI_Init(&argc, &argv);
  MPI_Comm_size(MPI_COMM_WORLD, &npr);
  MPI_Comm_rank(MPI_COMM_WORLD, &pid);

  for (i=pid; i<65536; i += npr)  test(pid, i);

  MPI_Finalize();
  return (0);
}
```

```
/*****************************************************************************
      envio.c
      se envia un vector desde el procesador 0 al 1
*****************************************************************************/

#include <mpi.h>
#include <stdio.h>

#define N 10

int main (int argc, char **argv)
{
  int   pid, npr, origen, destino, tag, ndat;
  int   VA[N], i;
  MPI_Status    info;

  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &pid);
  MPI_Comm_size(MPI_COMM_WORLD, &npr);

  for (i=0; i<N; i++) VA[i] = 0;


  if (pid == 0)
  {
    for (i=0; i<N; i++) VA[i] = i;
    destino = 1; tag = 0;
    MPI_Send(&VA[0], N, MPI_INT, destino, tag, MPI_COMM_WORLD);
  }

  else if (pid == 1)
  {
    printf("\n Valor de VA en P1 antes de recibir datos\n\n");
    for (i=0; i<N; i++) printf("%4d", VA[i]);
    printf("\n\n");

    origen = 0; tag = 0;
    MPI_Recv(&VA[0], N, MPI_INT, origen, tag, MPI_COMM_WORLD, &info);

    MPI_Get_count(&info, MPI_INT, &ndat);
    printf(" P1 recibe VA de P%d: tag %d, ndat %d \n\n",
            info.MPI_SOURCE, info.MPI_TAG, ndat);
    for (i=0; i<N; i++) printf("%4d", VA[i]);
    printf("\n\n");
  }

  MPI_Finalize();
  return (0);
}
```

```
/*************************************************************
       probe.c
       ejemplo de uso de la funcion probe de MPI
*************************************************************/

#include <mpi.h>
#include <stdio.h>


int main (int argc, char **argv)
{
  int   pid, npr, origen, destino, tag;
  int   i, longitud, tam;
  int   *VA, *VB;
  MPI_Status    info;

  MPI_Init(&argc, &argv);
  MPI_Comm_rank(MPI_COMM_WORLD, &pid);
  MPI_Comm_size(MPI_COMM_WORLD, &npr);

  if (pid == 0)
  {
    srand(time(NULL));
    longitud = rand() % 100;
    VA = (int *) malloc (longitud*sizeof(int));
    for (i=0; i<longitud; i++) VA[i] = i;

    printf("\n Valor de VA en P0 antes de enviar los datos\n\n");
    for (i=0; i<longitud; i++) printf("%4d", VA[i]);
    printf("\n\n");

    destino = 1; tag = 0;
    MPI_Send(&VA[0], longitud, MPI_INT, destino, tag, MPI_COMM_WORLD);
    free(VA);
  }
  else if (pid == 1)
  {
    origen = 0;  tag = 0;
    MPI_Probe(origen, tag, MPI_COMM_WORLD, &info);
    MPI_Get_count(&info, MPI_INT, &tam);

    if(tam != MPI_UNDEFINED)
    {
      VB = (int *) malloc(tam*sizeof(int));
      MPI_Recv(&VB[0], tam, MPI_INT, origen, tag, MPI_COMM_WORLD, &info);
    }

    printf("\n Valor de VB en P1 tras recibir los datos\n\n");
    for (i=0; i<tam; i++) printf("%4d", VB[i]);
    printf("\n\n");
    free(VB);
  }
  MPI_Finalize();
  return (0);
}
```

Ejercicios a realizar en el laboratorio (fase inicial)

Como complemento de las primeras sesiones de laboratorio, tienes que realizar estos dos ejercicios:

0.1 En el programa MPI `envio.c`, el proceso P0 genera el vector VA de 10 elementos y se lo envía a P1, que lo recibe e imprime. Modifica el programa para que P1 devuelva a P0 la suma de los elementos del vector recibido, y este último imprima el resultado.

0.2 El programa `circu.c` ejecuta en paralelo un bucle en el que se buscan las soluciones de una función lógica de 16 variables, testeando el resultado de la función para todos los posibles valores de entrada. El reparto de las iteraciones del bucle es estático entrelazado, y se imprimen las combinaciones de entrada que hacen que la función valga 1.

Modifica el programa para que P0 imprima el número total de soluciones encontradas.

Puzle sobre conceptos de programación paralela, MPI

De cara a estudiar cómo construir programas paralelos eficientes mediante MPI, y para preparar el camino para el diseño y programación de la aplicación que define el proyecto sobre MPI, hemos dividido las cuestiones más relevantes en tres partes, con las que organizar un puzle.

Cada persona del grupo debe preparar una de la partes del puzle, reunirse con la persona equivalente del resto de grupos para debatir y aclarar cuestiones, y finalmente compartir con el resto de personas del grupo lo aprendido.

Cada parte del puzle conlleva el estudio de las cuestiones que se refieren y la realización, ejecución y comprobación de los resultados de los programas que se proponen.

Tras la introducción general que hemos realizado en el laboratorio viendo cómo utilizar el *cluster* y analizando las funciones de comunicación básicas de MPI, las tres partes del puzle son las siguientes:

1. Comunicaciones colectivas
2. Tipos de datos derivados y comunicadores
3. Reparto dinámico de la carga y problemas en las fronteras del reparto de datos.

MPI: Puzle (1)

Comunicaciones colectivas

La comunicación es un aspecto importante en la programación de aplicaciones en sistemas paralelos. Como hemos estudiado, en estos sistemas la comunicación entre procesos se realiza mediante paso de mensajes. En las sesiones de laboratorio hemos visto las funciones básicas de comunicación punto a punto en MPI (`MPI_Send` y `MPI_Recv`), pero existe otro tipo de funciones que permiten una comunicación más eficiente entre procesos, y que simplifican la programación paralela en la mayoría de las aplicaciones. Se trata de las funciones de comunicación colectivas.

Mediante esta actividad deberás entender en qué consiste la comunicación colectiva, qué tipo de funciones existen, y su utilización en la programación en MPI. Para ello, te indicamos unas referencias (puedes encontrar fácilmente muchas más) para poder consultar y preparar una breve exposición del tema para tu grupo.

De cara a asentar los conceptos utilizados, deberás entregar las soluciones de los tres ejercicios que te proponemos, explicando la resolución de los mismos en un breve documento (1 o 2 caras máximo). El código base de los programas está en tu cuenta, en el directorio `templates/puzle`.

> Referencias generales

- www.mpi-forum.org/docs/docs.html
- computing.llnl.gov/tutorials/mpi/
- Pacheco P.: *Parallel Programming with MPI*. Morgan Kaufmann, 1997
- Gropp W., Lusk E., Skjellum A.: *Using MPI. Portable Parallel Programming with the Message-Passing Interface*. The MIT Press, 1999.

> Referencias sobre comunicaciones colectivas

- Pacheco P.: *An Introduction to Parallel Programming*. Morgan Kaufmann, 2011. Capítulo 3, apartado 4.
- Snir M., Otto S., Huss-Lederman S., Walker D., Dongarra J. *MPI: The Complete Reference, Volume 1, The MPI Core*. The MIT Press, 1999. Capítulo 4.

Ejercicios de la primera parte del puzle

P1.1 Hay que repartir un vector de N elementos entre `npr` procesos. Completa el programa serie `P11-distribute0.c`, para que genere el tamaño de cada trozo del vector y el desplazamiento desde el origen del vector al comienzo de cada trozo, en estos dos casos:

a. los posibles restos se añaden al último trozo

b. los posibles restos se añaden uno a uno a diferentes trozos.

Por ejemplo, si ejecutas el programa con estos datos: N = 17, `npr` = 5, debe imprimir:

```
  Data to distribute: N and npr
17
5

   FIRST DISTRIBUTION: the remainder for the last process

    3   0
    3   3
    3   6
    3   9
    5   12

   SECOND DISTRIBUTION: the remainder distributed (+1) among the first processes

    4   0
    4   4
    3   8
    3   11
    3   14
```

P1.2 El programa `P12-inteser.c` calcula el valor de una integral mediante el conocido método de sumar las áreas de *n* trapecios bajo la curva que representa a la función. A mayor valor de *n*, más preciso es el resultado.

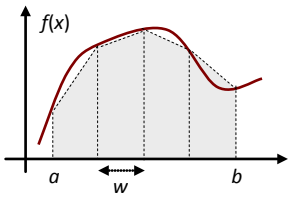

Completa el programa MPI `P12-intepar0.c` para realizar esa misma función entre *P* procesos, utilizando funciones de comunicación colectiva. Compara el resultado con el de la versión serie. Por ejemplo, si ejecutas el programa en 4 procesadores con estos datos, el resultado debe ser:

```
  Introduce a, b (limits) and n (num. of trap.)
0
10
10000000

  Integral (= ln x+1 + atan x), from 0.0 to 10.0, 10000000 trap.) = 3.869022947101
  Execution time (4 proc.) = 47.474 ms
```

P1.3 En una ejecución con cuatro procesos, P2 reparte datos del vector B (de 16 enteros) de la siguiente manera: a P0: B[3], B[4], B[5]; a P1: B[7], B[8]; a P2: B[10]; y a P3: B[12], B[13], B[14], B[15]. Tras ello, cada proceso suma 100 a los elementos recibidos, y, finalmente, se recopilan los datos finales en P2, en las mismas posiciones iniciales del vector B.

Completa el programa MPI `P13-scatter-gather0.c` para que realice esa función; al principio, P2 debe inicializar el vector a `B[i] = i`, y, al final, imprimir el nuevo vector B. El programa debe imprimir:

```
B in pid=2 after the calculation
   0   1   2 103 104 105   6 107 108   9 110  11 112 113 114 115
```

MPI: Puzle (2)

Tipos de datos derivados / comunicadores

En los ejemplos que hemos realizado en el laboratorio se han intercambiado datos con una estructura muy simple (enteros, flotantes, etc. consecutivos), pero en muchas ocasiones es necesario disponer de mayor flexibilidad en la definición de los datos que se desean enviar y recibir (por ejemplo, datos no consecutivos en memoria, de tipos diferentes…). Además, el coste de enviar múltiples datos en varios mensajes es mayor que el coste de enviar la misma cantidad de datos en un único mensaje. Por ello, MPI ofrece diferentes alternativas para el envío de datos en diferentes "formatos", que permiten reducir las latencias de la comunicación entre los procesos.

Por otra parte, otro aspecto importante en la comunicación entre procesos es la agrupación de dichos procesos en comunicadores diferentes al `MPI_COMM_WORLD` inicial. Esto permite que cada proceso se pueda identificar de maneras diferentes, según al grupo o comunicador con el que quiera trabajar.

Mediante esta actividad deberás comprender qué alternativas ofrece MPI para estructurar los datos de los mensajes y cómo se utilizan, así como la manera de definir y gestionar grupos de procesos diferentes al inicial. Para ello, te indicamos unas referencias (puedes encontrar fácilmente muchas más) para poder consultar y preparar una breve exposición del tema para tu grupo.

De cara a asentar los conceptos utilizados, deberás entregar las soluciones de los tres ejercicios que te proponemos, explicando la resolución de los mismos en un breve documento (1 o 2 caras máximo). El código base de los programas está en tu cuenta, en el directorio `templates/puzle`.

> Referencias generales

- www.mpi-forum.org/docs/docs.html
- computing.llnl.gov/tutorials/mpi/
- Pacheco P.: *An Introduction to Parallel Programming*. Morgan Kaufmann, 2011.
- Gropp W., Lusk E., Skjellum A.: *Using MPI. Portable Parallel Programming with the Message-Passing Interface*. The MIT Press, 1999.

> Referencias sobre tipos de datos derivados y comunicadores

- Pacheco P.: *Parallel Programming with MPI.* Morgan Kaufmann, 1997. Capítulo 6, apartados 2, 3 y 5; capítulo 7, apartados 3-5.
- Snir M., Otto S., Huss-Lederman S., Walker D., Dongarra J. *MPI: The Complete Reference, Volume 1, The MPI Core*. The MIT Press, 1999. Capítulo 3, apartados 4, 5 y 12; capítulo 5, apartados 1, 2 y 4.

Ejercicios de la segunda parte del puzle

P2.1 En un programa MPI, el proceso P3 tiene una matriz MAT de 5x5 enteros, de la que tiene que enviar la diagonal al resto de procesos. Completa el programa `P21-diagonal0.c` para que ejecute es operación en estos dos casos:

- la diagonal se recibe en los otros procesos como un simple vector, y se calcula e imprime la suma de los elementos recibidos.
- la diagonal se recibe sustituyendo a la diagonal de la matriz local MAT.

Ejecuta el programa con 4 procesos. Debe imprimir:

```
The sum of the received data in P1 is: 40
The new diagonal of MAT in P0 is:  0  4   8  12  16
```

P2.2 Completa el programa `P22-pack0.c`, para que P1 envíe a P2 tres elementos en un solo mensaje: una matriz A de 100x100 enteros, un vector B de 2.000 flotantes, y C, un *double*. Para ello, P1 empaqueta los datos y envía el paquete a P2; por su parte, P2 recibe el mensaje y desempaqueta los datos.

Ejecuta el programa con 4 procesos. Debe imprimir:

```
Received in P2: A[10][10] = 100   B[33] = 13.2   C = 2.2
```

P2.3 Una aplicación paralela se ejecuta en 8 procesos. En un momento dado, necesitamos construir dos grupos diferentes, de 4 procesos cada uno: los procesos 0 a 3 por un lado, y los procesos 4 a 7 por otro. En cada grupo, los procesos tendrán un nuevo identificador.

Tras ello, en cada grupo se efectúa una operación de recogida de datos, de tal manera que, partiendo de vectores V de 5 enteros en cada proceso (inicializados al valor del `pid` del proceso), al final todos ellos dispongan del vector W de 20 elementos, formado por la concatenación de los vectores V de los 4 procesos de cada grupo.

Completa el programa `P23-groups0.c` para que realice esa función. Ejecuta el programa con 8 procesos; debe imprimir:

```
I am pid: 0 and pid2: 0 and W(0,5,10,15) are 0 1 2 3
I am pid: 4 and pid2: 0 and W(0,5,10,15) are 4 5 6 7
```

MPI: Puzle (3)

Reparto dinámico de carga / El problema de la "frontera"

Para lograr un buen reparto de la carga de trabajo, cuando no conocemos a priori el tiempo de ejecución de las tareas, es necesario efectuar un reparto dinámico de las mismas, es decir, en tiempo de ejecución.

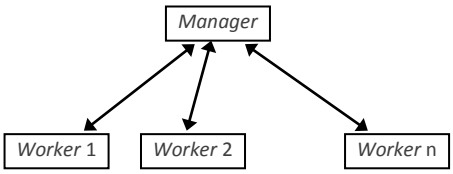

En esos casos, es habitual utilizar el conocido modelo de programación "*manager/worker*", en el que uno de los procesos, el *manager*, se encarga, por un lado, de repartir tareas bajo demanda y, por otro, de recoger resultados. El resto de procesos, los *workers*, solicitan tareas, las ejecutan, y devuelven resultados, hasta completar entre todos la carga inicial de trabajo.

Este puede ser el algoritmo general:

```
si manager
    mientras haya trabajo
        espera peticiones
        envía trabajo
        recoge resultados / envía trabajo

    si no hay más trabajo
        recoge resultados / envía código fin de trabajo

si worker
    mientras no fin de trabajo
        pide trabajo
        ejecuta trabajo
        envía resultados / pide trabajo
```

Por otro lado, otro problema típico de las aplicaciones paralelas es el de las "fronteras" en el reparto de los datos. Por ejemplo, al repartir un vector el último elemento de un trozo y el primero del siguiente pasan de ser consecutivos en memoria a estar en diferentes procesadores, por lo que si hay alguna relación entre ellos es necesario efectuar operaciones explicitas de comunicación.

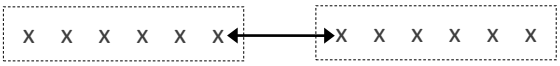

Mediante esta actividad deberás de comprender los dos problemas planteados: el reparto dinámico de tareas mediante un modelo de programación *manager/worker* y el intercambio de datos en las fronteras del reparto, y preparar una breve exposición de estas cuestiones para tu grupo.

De cara a asentar los conceptos utilizados, deberás entregar las soluciones de los dos ejercicios que te proponemos, explicando la resolución de los mismos en un breve documento (1 o 2 caras máximo). El código base de los programas está en tu cuenta, en el directorio `templates/puzle`.

Ejercicios de la tercera parte del puzle

P3.1 El programa `P31-collatzser.c` aplica una función basada en el algoritmo de Collatz a números enteros desde 1 a 320, con una carga de trabajo proporcional al número de iteraciones necesarias para que los números converjan a 1.

Hay que hacer dos versiones paralelas de ese programa. En la primera, se reparten las tareas (procesar los números) entre todos los procesos de modo estático consecutivo, procesando cada uno de ellos 320/`npr` números consecutivos.

En la segunda, el reparto de tareas debe ser dinámico, bajo demanda. Uno de los procesos (P0, por ejemplo) funciona como *manager* y reparte a cada uno de los restantes procesos (*workers*) números a procesar, uno a uno, cuando se lo solicitan. Cada *worker* procesa ese número, y devuelve al *manager* el número de iteraciones que ha necesitado para converger. Si quedan números por analizar, se le envía una nueva tarea, hasta terminar de analizar entre todos los *workers* todos los números. El proceso *manager* debe controlar cuántos números ha procesado cada *worker*, y el número que ha necesitado más iteraciones para converger.

Una vez verificados ambos programas, ejecuta la versión estática con 2, 4, 8, 16, 32 y 64 procesos; y la versión dinámica con 1+1, 1+2, 1+4, 1+8, 1+16, 1+32 y 1+63 procesos. Obtén los tiempos de ejecución y calcula los *speed-ups* y las eficiencias obtenidas. Dibuja el comportamiento de ambos parámetros en función del número de procesos y explica los resultados.

P3.2 En una determinada aplicación (`P32-convoser.c`) se procesa un vector de `N` = 1.002 elementos al que se aplica una operación de convolución de manera iterativa

```
for (i=1; i<N-1; i++) Aux[i] = (A[i-1] + 2*A[i] + A[i+1]) / 4
for (i=1; i<N-1; i++) A[i] = Aux[i]
```

hasta que el valor máximo de los elementos del vector sea menor al 60% del valor máximo inicial. Como puedes ver, el primer y último elemento del vector no se procesan.

El programa se va a ejecutar con un número de procesos divisor de 1.000. Escribe un versión paralela del programa en el que **(a)** P0 reparte los 1.000 elementos el vector que hay que procesar, en trozos de 1000/`npr` elementos: el primero lo procesará él mismo, el segundo P1…; **(b)** cada proceso efectúa la operación sobre el trozo de vector que le ha tocado y calcula el máximo local; **(c)** los procesos envían su máximo local a P0, que calcula el máximo global y, tras ello, avisa a todos los procesos si hay que efectuar una nueva iteración de convolución o si la operación ha terminado.; **(d)** al acabar, los procesos envían a P0 su trozo de vector A procesado, para que éste los reconstruya.

Ten en cuenta que cada procesador va a necesitar para procesar su trozo los datos que le han correspondido y 2 más, el anterior al primer elemento y el posterior al último, que estarán en el procesador anterior y en el siguiente. Por tanto, te sugerimos que cada proceso utilice un buffer de 1 + 1000/`npr` + 1 elementos, y que previo a la operación de convolución se intercambien con `pid`-1 y `pid`+1 los datos que necesiten (que van a ir cambiando iteración a iteración).

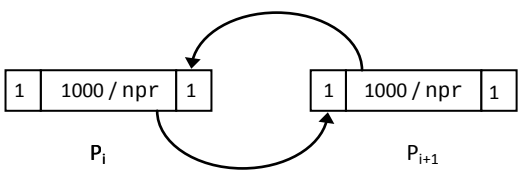

Ejercicios complementarios

Aquí tienes unos ejercicios por si quieres hacer alguna prueba más tras la puesta en común del puzle.

C1 En una aplicación paralela, el proceso `pid = 0` recibe de los otros procesos mensajes de diferente longitud con datos (enteros), que procesa ejecutando la función `PROC(*dat,tam)`, donde `*dat` es la dirección de comienzo de los datos y `tam` su tamaño. Al recibir un mensaje, se responde con un mensaje corto (un entero) para confirmar la recepción y se procesan los datos. Escribe el código que ejecutará P0 para realizar esta tarea si:

a. hay que recibir y procesar los mensajes en orden estricto de `pid` (P1, luego P2…).
b. queremos recibir y procesar los mensajes en el orden en que llegan.

C2 En una aplicación paralela, el proceso P0 envía una matriz `M[N][N]` a P1. P1 no conoce el tamaño de la matriz que va a recibir, por lo que primero mira en el buzón, y con esa información reserva espacio para la matriz y a continuación la recibe. Escribe el trozo de código MPI que realiza esa función. Ejecuta un caso concreto y comprueba que el resultado es el esperado.

C3 En una ejecución en paralelo, el procesador P3 va a recibir un mensaje del procesador P1, pero no conoce ni el tamaño de los datos ni el `tag` del mensaje. Si el `tag` es 0, entonces el mensaje llevará un vector de 100 enteros; si el `tag` es 1, el mensaje llevará solamente un flotante. Escribe el código correspondiente para que envíen y reciban correctamente esos mensajes entre P1 y P3. Ejecuta un caso concreto y comprueba que es correcto.

C4 En un momento dado de la ejecución de una aplicación en paralelo, cada proceso dispone de una matriz A de 10×10 enteros, y todos ellos necesitan, para continuar con la ejecución, la matriz suma de todas esas matrices. Escribe el código necesario para esa operación, utilizando funciones de comunicación colectiva. Como prueba, ejecuta el programa con 8 procesos, inicializa las matrices al valor del `pid` de cada proceso, y haz que un par de procesos (P2 y P4 por ejemplo) impriman el resultado.

C5 El programa `matvecser.c` efectúa el siguiente cálculo con matrices y vectores:

```
double A[N][N], B[N], C[N], D[N], PE

C[N] = A[N][N] * B[N]
D[N] = A[N][N] * C[N]
PE = ∑(C[i]· D[i])
```

Al principio se pide el tamaño de los vectores, N, tras lo cual reserva memoria para los mismos.

Escribe y ejecuta una versión paralela del programa serie. La inicialización de los datos previa al cálculo se realiza en un solo procesador (P0); al final, C, D y PE tienen que quedar en P0. La versión paralela debe permitir un reparto de datos de tamaño variable (funciones _v), es decir, que debe funcionar para cualquier N y para cualquier número de procesos. Previo a escribir código, analiza las operaciones que se ejecutan, y decide con qué datos va a trabajar cada proceso y cómo quieres repartirlos, para que puedas efectuar correctamente las reservas de memoria en cada proceso y las funciones de comunicación. Comprueba los resultados comparándolos con los de la versión serie.

C6 En un programa MPI, el proceso P0 tiene una matriz A de 10x10 enteros, de la que tiene que enviar al resto de procesos los elementos de la periferia (primera y última fila y primera y última columna), quienes copian esos datos en las posiciones correspondientes de sus matrices. Define los tipos necesarios, empaqueta las dos filas y las dos columnas, y envía el paquete a todos los procesos. Como comprobación, P1 imprime la nueva matriz.

C7 En una ejecución en paralelo, el proceso P0 tiene una matriz A de 10x10 enteros, de la que a menudo debe enviar a P1, en un solo mensaje, submatrices B (trozos 2D) de tamaño 3x3.

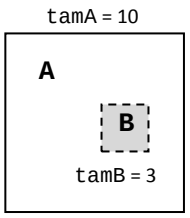

Escribe un programa paralelo que realice esa función. Para ello: **(a)** define un tipo de datos derivado adecuado para esa estructura; y **(b)** envía a P1 la correspondiente matriz B de 3x3 que comienza en el elemento (2,5) de la matriz A.

Inicializa la matriz A a estos valores:

```
for(i=0; i<tamA; i++)
   for(j=0; j<tamA; j++) A[i][j] = i + j;
```

Imprime la matriz recibida en P1, que debe ser:

7	8	9
8	9	10
9	10	11

C8 Queremos enviar una matriz A de P0 a P1, de tal manera que P1 se quede con la matriz A traspuesta. Para ello:

1 Define el tipo columna.
2 P0 envía las columnas de A una a una a P1.
3. P1 recibe las columnas y las guarda como filas de una matriz, que terminará siendo la traspuesta de A.

Como verificación, ejecuta el caso de una matriz pequeña de 4x4, inicialízala en P0 a números aleatorios y haz que ambos procesos impriman la matriz.

¿Se puede hacer esa operación con un solo envío? ¿Cómo?

Aplicación a paralelizar usando MPI

Tras la fase de aprendizaje desarrollada en formato "puzle" disponemos ya de las herramientas y estrategias necesarias para afrontar con éxito la paralelización de una determinada aplicación. Como vimos en la presentación del proyecto, se trata de una aplicación que simula el comportamiento térmico de una tarjeta de circuitos impresos, buscando la mejor distribución de los chips en la misma, aquella que minimice la temperatura media final de la tarjeta.

▪ Descripción de la aplicación

El programa `heats.c` es la versión serie de la aplicación que hay que paralelizar. Se trata de un caso concreto de resolución de ecuaciones en diferencias parciales (tipo Poisson), que son muy habituales en muchas aplicaciones técnico-científicas.

En nuestro caso, partimos de la definición de una tarjeta en la que se colocan varios chips, cada uno de los cuales inyecta una determinada cantidad de calor. Este calor se va a distribuir por toda la tarjeta, hasta llegar a una situación estacionaria. Para calcular la temperatura media se divide la tarjeta en una rejilla 2D de puntos, y la temperatura de cada punto se va modificando, de manera iterativa, en función de su temperatura y de la de sus vecinos, de acuerdo a la siguiente función:

$$\mathbf{T^1_{i,j}} = T^0_{i,j} + 0{,}1 \times [\Sigma T^0 \text{ de los 8 vecinos} - 8 \times T^0_{i,j}]$$

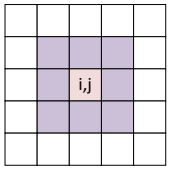

Tras calcular, de acuerdo a la expresión anterior, la nueva temperatura de cada punto (`i`,`j`) de la rejilla a partir de las temperaturas anteriores, se inyecta calor en los puntos que ocupan los chips y se disipa calor en posiciones concretas de la tarjeta, que están ventiladas. El proceso de "actualización" de calor y de "difusión" del mismo se repite en toda la rejilla hasta que la temperatura media se estabilice o se haya efectuado un número de iteraciones máximo prefijado. Estas dos operaciones se realizan respectivamente en las funciones `difussion` y `thermal_update`

>> difussion

```
while (end == 0)
{
  niter++;
  Tmean = 0.0;

  // heat injection and air cooling
  thermal_update (param, grid, grid_chips);

  // thermal difussion
  for (i=1; i<NROW-1; i++)
  for (j=1; j<NCOL-1; j++)
  {
    T = grid[i*NCOL+j] +
        0.10 * (grid[(i+1)*NCOL+j] + grid[(i-1)*NCOL+j] + grid[i*NCOL+(j+1)] +
         grid[i*NCOL+(j-1)] + grid[(i+1)*NCOL+j+1] + grid[(i-1)*NCOL+j+1] +
         grid[(i+1)*NCOL+(j-1)] + grid[(i-1)*NCOL+(j-1)]
         - 8*grid[i*NCOL+j]);

    grid_aux[i*NCOL+j] = T;
    Tmean += T;
  }

  //new values for the grid
  for (i=1; i<NROW-1; i++)
  for (j=1; j<NCOL-1; j++)
    grid[i*NCOL+j] = grid_aux[i*NCOL+j];

  // convergence every 10 iterations
  if (niter % 10 == 0)
  {
    Tmean = Tmean / ((NCOL-2)*(NROW-2));
    if ((fabs(Tmean - Tmean0) < param.t_delta) || (niter > param.max_iter))
         end = 1;
    else Tmean0 = Tmean;
  }
} // end while
```

>> thermal_update

```
// heat injection at chip positions
 for (i=1; i<NROW-1; i++)
 for (j=1; j<NCOL-1; j++)
   if (grid_chips[i*NCOL+j] > grid[i*NCOL+j])
     grid[i*NCOL+j] += 0.05 * (grid_chips[i*NCOL+j] - grid[i*NCOL+j]);

 // air cooling at the middle of the card
 for (i=1; i<NROW-1; i++)
 for (j=0.45*(NCOL-2)+1; j<0.55*(NCOL-2)+1; j++)
     grid[i*NCOL+j] -= 0.01 * (grid[i*NCOL+j] - param.t_ext);
```

Los puntos de la rejilla 2D (`grid`) que representan la tarjeta se inicializan a una temperatura ambiente prefijada, que se va modificando en función de la temperatura de los chips. En todo caso, los puntos que representan los bordes horizontales y verticales de la tarjeta no se procesan, por lo que mantienen siempre su temperatura inicial.

Una matriz 2D del mismo tamaño (`grid_chips`) representa las temperaturas de los puntos que ocupan los chips en la tarjeta, puntos en los que se inyecta calor. Esta matriz se inicializa a partir de un

fichero de entrada que define las posiciones, tamaños, temperaturas, etc. de los chips de la tarjeta. En sentido contrario, una franja vertical central de la tarjeta está ventilada, por lo que en esos puntos se reduce la temperatura tras cada iteración. Ambas operaciones, inyección de calor y ventilación, se reflejan en la función `thermal_update`.

El algoritmo de difusión del calor utiliza dos matrices, una con las temperaturas actuales en cada punto (`grid`) y otra con los nuevos valores que se están calculando en esa iteración (`grid_aux`). Al final de la iteración, se vuelca una matriz en la otra.

La actualización de la temperatura media de la tarjeta, `Tmean`, se puede hacer en cada iteración o tras varias iteraciones; en este caso, se hace cada 10 iteraciones. La variable `Tmean0` representa la anterior temperatura media (inicialmente, la temperatura ambiente); si la diferencia entre la actual temperatura media y la anterior es menor que un cierto valor predeterminado, finalizamos la simulación.

El programa principal es sencillo:

```
{
  ...
  read_data (argv[1], &param);
  ...

  // loop to process chip configurations
  for (conf=0; conf<param.nconf; conf++)
  {
    gettimeofday (&t0, 0);

    // initial values for grids
    init_grid_chips (conf, param, grid_chips);
    init_grids (param, grid, grid_aux);

    // main loop: thermal injection/disipation until convergence (t_delta or max_iter)
    diffusion (param, grid, grid_chips, grid_aux);

    // writing configuration results
    gettimeofday (&t1, 0);
    tej[conf] = (t1.tv_sec - t0.tv_sec) + (t1.tv_usec - t0.tv_usec)/1e6;
    results_conf (conf, param, grid, grid_chips, &BT);
  }

  // writing best configuration results
  results (param, &BT, argv[1]);
  for (conf=0; conf<param.nconf; conf++) tsim += tej[conf];
  printf ("   > Time (serial): %1.3f s \n\n", tsim);
}
```

La función `read_data` lee el fichero con las diferentes configuraciones de la tarjeta que hay que simular. Los datos se guardan en la variable `param`, un *struct* con los siguientes campos:

```
struct info_param {
  int    nconf, nchip;
  float  t_ext, tmax_chip, t_delta;
  int    max_iter, scale;
  struct info_chip **chips;
};
```

```
struct info_chip {
  int    x, y, h, w;
  float  tchip;
};
```

`nconf`:	número de configuraciones diferentes que hay que simular; cada configuración está compuesta por los mismos chips, pero en diferentes posiciones de la tarjeta.
`nchip`:	número de chips que tiene la tarjeta.
`t_ext`:	temperatura ambiente a la que se inicializa la rejilla de puntos.
`tmax_chip`:	temperatura máxima de los chips.
`t_delta`:	criterio de finalización de la simulación: diferencias de temperatura media menores que ese valor.
`max_iter`:	criterio de finalización de la simulación: número máximo de iteraciones.

`scale`: factor de escala de la simulación (de 1 a 12); el valor 1 representa una rejilla de 200x100 puntos, que usaremos para las pruebas durante el desarrollo de la aplicación; un valor 10 representa una rejilla de 2000 x1000 puntos, y es el que utilizaremos para la obtención de resultados, una vez programada la aplicación.

`chips`: un *struct* con la información de cada chip: posición en la tarjeta base (x,y), tamaño (h,w), y temperatura (`tchip`).

▪ Definición de la tarjeta

El **fichero de entrada** que define la tarjeta, y de donde se leen los datos de partida, tiene la siguiente estructura (es un ejemplo):

```
3   4   20.0  160.0  0.01  10000   10
```
Núm. de configuraciones a simular (3); núm. de chips (4); temp. ambiente (20.0); temp. máxima de un chip (160.0); criterios de convergencia: temperatura (0.01) y núm. máximo de iteraciones (10000); factor de escala (10).

```
40   40   100.0
50   20   160.0
30   60   120.0
20   20   80.0
```
Una línea con la definición de cada chip de la tarjeta: por ejemplo, el primero, tamaño (40x40) y temperatura máxima (100.0)

```
86   15
135   49
21   27
90   59
```
Primera configuración a simular: coordenadas (x,y) del vértice superior izquierdo de cada chip. P.e., primer chip: 86, 15; al ser de tamaño 40, 40 ocupará las posiciones (86-125, 15-54) en la rejilla básica de 200x100 puntos.

```
126   40
26   72
168   29
62   23
```
Segunda configuración a simular: coordenadas (x,y) del vértice superior izquierdo de cada chip.

```
67   35
129    2
22   11
119   84
```
Tercera configuración a simular: coordenadas (x,y) del vértice superior izquierdo de cada chip.

El fichero `card` contiene la descripción de las configuraciones que hay que simular. Se trata de 20 configuraciones diferentes de 4 chips, con una rejilla de 2000x1000 puntos (factor de escala 10).

Dado que el tiempo de ejecución es elevado, para las pruebas iniciales vamos a usar el fichero `card0`, que contiene solo cuatro configuraciones, en el tamaño base de la rejilla, 200x100 puntos.

Para ejecutar el programa hay que indicar la tarjeta a simular junto con el ejecutable. Por ejemplo:

```
> heats card0
```

▪ Resultados

Como resultado de la simulación, se guarda en un *struct* (BT) los resultados de la configuración que menor temperatura media produce: número de configuración, temperatura media, matriz inicial de chips y matriz final de temperaturas. El programa genera con esos resultados dos ficheros: `card_ser.chips` (la matriz de los chips) y `card_ser.res` (la matriz final de temperaturas).

Una aplicación sencilla de visualización permite representar esas dos matrices para el caso de pruebas con factor de escala 1 (`card0`, matrices de 200x100 puntos), ejecutando:

```
> vfinder card0_ser.res
```

que abre una ventana y dibuja en diferentes colores la distribución de temperaturas obtenida (que puedes comparar con la inicial, que se encuentra en el fichero `card0_ser.chips`).

▪ Estructura del programa

El programa serie está dividido en tres módulos: `heats.c` (programa principal), `difussion.c` (que contiene las rutinas `thermal_update` y `difussion`), y `faux.c` (con las rutinas auxiliares de lectura de datos y generación de resultados).

Todos los ficheros (módulos fuente `.c`, ficheros de cabecera `.h`, y definición de tarjetas) los tienes en el directorio `templates/aplicacion`.

▪ Tareas a realizar

Hay que paralelizar el programa serie para poder ejecutarlo en el *cluster*. Se propone realizar dos versiones del código paralelo.

>> Fase 1

Cada configuración de las 20 se va a ejecutar en paralelo entre todos los procesos; tras terminar la primera, se pasa a simular la segunda, la tercera, etc., hasta acabar con todas.

La rejilla de puntos de la tarjeta la vamos a repartir entre los procesos por franjas horizontales. Ten en cuenta que, de manera similar a como has resuelto el problema 3.2 del puzle, en cada iteración cada proceso va a necesitar datos, los correspondientes a las fronteras, que ese encuentran en los procesos `pid+1` y `pid-1`.

Puedes comprobar que los ficheros de resultados que obtienes son correctos, por ejemplo, mediante una comparación entre ellos con el comando `diff`:

```
> diff card0_ser.res card0_par.res
```

y visualizar la distribución de temperaturas ejecutando:

```
> vfinder card0_par.res    (o card0_par.chips)
```

Una vez verificado que el programa es correcto, ejecútalo con la tarjeta de configuraciones completa (`card`), en serie y con 2, 4, 8, 16, 24 y 32 procesos. Obtén los tiempos de ejecución, y calcula el factor de aceleración y los *speed-ups* conseguidos. Representa gráficamente esos datos y extrae las conclusiones pertinentes. En base a esos resultados, estima cuál es el número de procesos (*P*) más adecuado para este problema en este *cluster*.

>> Fase 2

Una vez completada la primera, hay que realizar una segunda versión con una estrategia diferente. En lugar de que todos los procesos se dediquen a ejecutar en paralelo cada configuración de chips, vamos a distribuir los procesos en un proceso *manager* y grupos de *P workers* (el valor estimado en la primera fase), y efectuar un planificación dinámica de las tareas, tal como has hecho en el ejercicio 3.1 del puzle.

Así, el *manager* distribuye una configuración a cada grupo bajo demanda de éstos. Cada grupo de *P* procesos simula una configuración y devuelve el resultado obtenido al *manager*, para que le envíe una nueva configuración para simular, hasta terminar con todas las configuraciones entre todos los grupos.

Para esta versión, tienes que definir y utilizar los grupos de procesos, para que se intercambien información entre ellos. En cada grupo de *P*, uno de ellos será el encargado de solicitar tareas al

manager y de devolverle resultados. En cada grupo, la simulación de la tarjeta se realiza con el mismo procedimiento de la primera versión.

Una vez verificado el programa (utilizando el fichero `card0`), ejecútalo con el fichero de entrada `card`. Mide los tiempos de ejecución para el caso de 1+1x*P*, 1+2x*P*, 1+3x*P*, 1+4x*P*… procesos, y calcula los *speed-ups* y eficiencias conseguidos.

Compara los resultados de ambas versiones y justifica los resultados que has obtenido.

>> Informe técnico

Como resultado del proyecto hay que escribir un informe técnico que describa el problema a resolver, cómo se ha resuelto, los resultados obtenidos y las conclusiones (para ambas fases). El informe debe contener las graficas, tablas de datos y trozos de código comentados necesarios para su correcta explicación, de acuerdo a las directrices del documento guía. Como anexo, hay que incluir el código completo de la aplicación.

>> Entregables

E6.1 Resultados preliminares de la fase 1 de la aplicación: resultados numéricos y gráficos obtenidos en la fase 1 (un par de hojas). Fecha: **26 de abril**.

E6.2 Informe técnico definitivo. Fecha: **20 de mayo**.

E6.3/E7 Presentación oral del trabajo realizado, y entrega de la carpeta final. Fecha: **24 de mayo**.

Código de la versión serie

```
/* File: defines.h */

// minimal card and maximun size
#define RSIZE 200
#define CSIZE 100
#define MAX_GRID_POINTS 3000000

#define NROW (RSIZE*param.scale + 2)
#define NCOL (CSIZE*param.scale + 2)

struct info_chip {
  int    x, y, h, w;
  float  tchip;
};

struct info_param {
  int    nconf, nchip;
  float  t_ext, tmax_chip, t_delta;
  int    max_iter, scale;
  struct info_chip **chips;
};

struct temp {
  double Tmean;
  int    conf;
  float  bgrid[MAX_GRID_POINTS];
  float  cgrid[MAX_GRID_POINTS];
};
```

```
/* File: heats.c */

#include <stdio.h>
#include <values.h>
#include <sys/time.h>

#include "defines.h"
#include "faux.h"
#include "difussion.h"


// global variables
float grid_chips[MAX_GRID_POINTS], grid[MAX_GRID_POINTS], grid_aux[MAX_GRID_POINTS];
struct temp BT;


/*****************************************************************************/
void init_grid_chips (int conf, struct info_param param, float *grid_chips)
{
  int i, j, n;

  for (i=0; i<NROW; i++)
  for (j=0; j<NCOL; j++)
    grid_chips[i*NCOL+j] = param.t_ext;

  for (n=0; n<param.nchip; n++)
  for (i=param.chips[conf][n].x*param.scale; i<(param.chips[conf][n].x+param.chips[conf][n].h)*param.scale; i++)
  for (j=param.chips[conf][n].y*param.scale; j<(param.chips[conf][n].y+param.chips[conf][n].w)*param.scale; j++)
    grid_chips[(i+1)*NCOL+(j+1)] = param.chips[conf][n].tchip;
}


/*****************************************************************************/
void init_grids (struct info_param param, float *grid, float *grid_aux)
{
  int i, j;

  for (i=0; i<NROW; i++)
  for (j=0; j<NCOL; j++)
    grid[i*NCOL+j] = grid_aux[i*NCOL+j] = param.t_ext;
}
```

```
/*****************************************************************************/
/*****************************************************************************/
int main (int argc, char *argv[])
{
  int    conf;
  struct info_param param;

  struct timeval t0, t1;
  double *tej, tsim = 0.0;


 // reading initial data file
  if (argc != 2) {
    printf ("\n\nERROR: needs a card description file \n\n");
    exit (-1);
  }

  read_data (argv[1], &param);

  printf ("\n  ======================================================================");
  printf ("\n    Thermal difussion - SERIAL version ");
  printf ("\n    %d x %d points, %d chips", RSIZE*param.scale, CSIZE*param.scale, param.nchip);
  printf ("\n     T_ext = %1.1f, Tmax_chip = %1.1f, T_delta: %1.3f, Max_iter: %d", param.t_ext, param.tmax_chip,
                param.t_delta, param.max_iter);
  printf ("\n  ======================================================================\n\n");

  BT.Tmean = MAXDOUBLE;
  tej = (double *) malloc(param.nconf * sizeof(double));


  // loop to process chip configurations
  for (conf=0; conf<param.nconf; conf++)
  {
    gettimeofday (&t0, 0);

    // inintial values for grids
    init_grid_chips (conf, param, grid_chips);
    init_grids (param, grid, grid_aux);

    // main loop: thermal injection/disipation until convergence (t_delta or max_iter)
    diffusion (param, grid, grid_chips, grid_aux);

    // processing configuration results
    gettimeofday (&t1, 0);
    tej[conf] = (t1.tv_sec - t0.tv_sec) + (t1.tv_usec - t0.tv_usec)/1e6;
    results_conf (conf, param, grid, grid_chips, &BT);
  }


  // writing best configuration results
  results (param, &BT, argv[1]);
  for (conf=0; conf<param.nconf; conf++) tsim += tej[conf];
  printf ("   > Time (serial): %1.3f s \n\n", tsim);
}
```

```
/* File: difussion.c */

#include "defines.h"


/*****************************************************************************/
void thermal_update (struct info_param param, float *grid, float *grid_chips)
{
  int i, j;

  // heat injection at chip positions
  for (i=1; i<NROW-1; i++)
  for (j=1; j<NCOL-1; j++)
    if (grid_chips[i*NCOL+j] > grid[i*NCOL+j])
      grid[i*NCOL+j] += 0.05 * (grid_chips[i*NCOL+j] - grid[i*NCOL+j]);

  // air cooling at the middle of the card
  int a = 0.45*(NCOL-2)+1;
  int b = 0.55*(NCOL-2)+1;

  for (i=1; i<NROW-1; i++)
  for (j=a; j<b; j++)
      grid[i*NCOL+j] -= 0.01 * (grid[i*NCOL+j] - param.t_ext);
}


/*****************************************************************************/
void diffusion (struct info_param param, float *grid, float *grid_chips, float *grid_aux)
{
  int    i, j, end, niter;
  float  T;
  double Tmean, Tmean0 = param.t_ext;

  end = 0; niter = 0;

  while (end == 0)
  {
    niter++;
    Tmean = 0.0;

    // heat injection and air cooling
    thermal_update (param, grid, grid_chips);

    // thermal difussion
    for (i=1; i<NROW-1; i++)
    for (j=1; j<NCOL-1; j++)
    {
      T = grid[i*NCOL+j] +
          0.10 * (grid[(i+1)*NCOL+j] + grid[(i-1)*NCOL+j] + grid[i*NCOL+(j+1)] + grid[i*NCOL+(j-1)] +
       grid[(i+1)*NCOL+j+1] + grid[(i-1)*NCOL+j+1] + grid[(i+1)*NCOL+(j-1)] + grid[(i-1)*NCOL+(j-1)]
       - 8*grid[i*NCOL+j]);

      grid_aux[i*NCOL+j] = T;
      Tmean += T;
    }

    //new values for the grid
    for (i=1; i<NROW-1; i++)
    for (j=1; j<NCOL-1; j++)
      grid[i*NCOL+j] = grid_aux[i*NCOL+j];

    // convergence every 10 iterations
    if (niter % 10 == 0)
    {
      Tmean = Tmean / ((NCOL-2)*(NROW-2));
      if ((fabs(Tmean - Tmean0) < param.t_delta) || (niter > param.max_iter))
           end = 1;
      else Tmean0 = Tmean;
    }
  } // end while
  printf ("Iter: %d\t", niter);
}
```

```
/* File: faux.c */

#include <stdio.h>
#include <values.h>

#include "defines.h"


/*****************************************************************************/
void read_data (char *file_name, struct info_param *param)
{
  int i, j, h, w;
  float tchip;
  FILE *fdin;

  fdin = fopen (file_name, "r");

  fscanf (fdin, "%d %d %f %f %f %d %d", &param->nconf, &param->nchip, &param->t_ext,
          &param->tmax_chip, &param->t_delta, &param->max_iter, &param->scale);
  if (param->scale > 12) {
    printf("\n\nERROR: maximum scale factor is 12 \n\n");
    exit (-1);
  }

  param->chips = (struct info_chip **) malloc(param->nconf*sizeof(struct info_chip*));
  for (i=0; i<param->nconf; i++)
    param->chips[i] = (struct info_chip *) malloc(param->nchip * sizeof(struct info_chip));

  // chip sizes and temperatures
  for (j=0; j<param->nchip; j++)
  {
    fscanf (fdin, "%d %d %f", &h, &w, &tchip);
    for (i=0; i<param->nconf; i++)
    {
      param->chips[i][j].h = h;
      param->chips[i][j].w = w;
      param->chips[i][j].tchip = tchip;
    }
  }

  // chip positions
  for (i=0; i<param->nconf; i++)
  for (j=0; j<param->nchip; j++)
    fscanf (fdin, "%d %d", &param->chips[i][j].x, &param->chips[i][j].y);

  fclose (fdin);
}


/*****************************************************************************/
void results_conf (int conf, struct info_param param, float *grid, float *grid_chips, struct temp *BT)
{
  int   i, j;
  float Tmax = MINFLOAT, Tmin = MAXFLOAT;
  double Tmean = 0.0;

  for (i=1; i<NROW-1; i++)
  for (j=1; j<NCOL-1; j++)
    Tmean += grid[i*NCOL+j];

  Tmean = Tmean / ((NROW-2)*(NCOL-2));

  if (BT->Tmean > Tmean)
  {
    BT->Tmean = Tmean;
    BT->conf = conf+1;
    for (i=1; i<NROW-1; i++)
    for (j=1; j<NCOL-1; j++)
    {
      BT->bgrid[i*NCOL+j] = grid[i*NCOL+j];
      BT->cgrid[i*NCOL+j] = grid_chips[i*NCOL+j];
    }
  }

  printf ("Config: %2d \t Tmean: %1.2f\n", conf+1, Tmean);
}
```

```
/*****************************************************************************/
void fprint_grid (FILE *fd, float *grid, struct info_param param)
{
  int i, j;

  // j - i order for better visualitation
  for (j=NCOL-2; j>0; j--)
  {
    for (i=1; i<NROW-1; i++) fprintf (fd, "%1.2f ", grid[i*NCOL+j]);
    fprintf (fd, "\n");
  }
  fprintf (fd, "\n");
}


/*****************************************************************************/
void results (struct info_param param, struct temp *BT, char *finput)
{
  FILE  *fd;
  char  name[100];

  printf ("\n\n >>> BEST CONFIGURATION: %2d\t Tmean: %1.2f\n\n", BT->conf, BT->Tmean);

  sprintf (name, "%s_ser.res", finput);
  fd = fopen (name, "w");
  fprintf (fd, "Tmin_ini %1.1f  Tmax_ini %1.1f  \n", param.t_ext, param.tmax_chip);
  fprintf (fd, "%d\t  %d \n", NCOL-2, NROW-2);

  fprint_grid (fd, BT->bgrid, param);

  fprintf (fd, "\n\n >>> BEST CONFIGURATION: %d\t Tmean: %1.2f\n\n", BT->conf, BT->Tmean);
  fclose (fd);

  sprintf (name, "%s_ser.chips", finput);
  fd = fopen (name, "w");
  fprintf (fd, "Tmin_chip %1.1f  Tmax_chip %1.1f  \n", param.t_ext, param.tmax_chip);
  fprintf (fd, "%d\t  %d \n", NCOL-2, NROW-2);

  fprint_grid (fd, BT->cgrid, param);

  fclose (fd);
}
```